

L^AT_EX Entrega 3 - Miniproyecto 1

John Acosta ⁺, Leticia Vidales [†], Juana Salazar [‡]
Estudiantes de Ingeniería Biomédica, Universidad de los Andes. 1
Bogotá, Colombia

1. Umbralización

- Mencione las ventajas y desventajas de cada uno de los métodos de umbralización.

Respuesta

Los resultados obtenidos tras haber realizado cada método de umbralización se observan en la [figura 1](#). En primer lugar, la principal ventaja que se destaca de la umbralización por percentiles es su capacidad de seleccionar en el histograma de intensidades el porcentaje que corresponde el umbral. Es decir, es útil para imágenes con condiciones de iluminación variables con múltiples picos, lo que permite separar mejor el primer plano del fondo [1]. Asimismo, otra ventaja que se diferencia de la umbralización arbitraria es que elimina el sesgo del usuario a causa de que selecciona automáticamente un umbral basado en medidas estadísticas [2]. En contraste, su principal desventaja es su costo computacional debido a los cálculos de percentiles. Del mismo modo que el umbral arbitrario, la imagen local funciona en función de la distribución de intensidad global y puede fallar si diferentes regiones tienen diferente iluminación [5].



Figure 1. La primera imagen representa la imagen original solo con el canal azul, la segunda ha sido umbralizada utilizando un umbral arbitrario, y la tercera ha sido umbralizada mediante un umbral basado en percentiles.

Ahora bien, las ventajas para la umbralización con un umbral arbitrario radican en su fácil reproducibilidad y bajo costo computacional. Igualmente, si la diferencia entre las intensidades de los píxeles que se quiere separar es muy fuerte, es sugerible usar este método

por su practicidad y rapidez [3]. No obstante, su principal desventaja es que si las intensidades de la imagen de dos tipos de tejido se solapan fuertemente o se incluye varios niveles de grises, al hacer que el histograma se comporte como una distribución uniforme, puede que no haya ninguna intensidad de imagen para la que el umbral separe el objeto de interés del fondo [4], lo cual al observar la [figura 1](#) es nuestro caso por los varios niveles de grises en la imagen. Asimismo, esta decisión depende del usuario, el que debe elegir manualmente un umbral, lo que puede implicar prueba y error para cada una de las imágenes.

- Mencione las ventajas y desventajas del método de umbralización otsu. ¿En este caso sería útil?

Respuesta

Inicialmente, Este método maximiza la separabilidad entre las diferentes clases de umbrales en los datos, basándose en una estimación inicial de los umbrales. Dado que los límites entre los distintos tipos de tejido suelen estar representados por bordes ascendentes y descendentes de picos en el histograma, la distinción de estos picos es importante para la segmentación basada en umbrales. Sin embargo, esta distinción se ve reducida a causa de que asume un histograma bimodal, que puede no ser adecuado para todas las imágenes y computacionalmente es más intensivo que las otras umbralizaciones [5].

2. Predicciones

- Respuesta

Inicialmente, un score de confianza idealmente debería reflejar la probabilidad de que el objeto detectado sea correcto. Ahora bien, si solo se considera un bbox de área positiva como score, el principal problema se presentan por la sensibilidad al ruido de fondo. Debido a que, píxeles blancos en un cuadro delimitador puede ser engañoso si hay ruido de fondo. En este sentido, si una imagen contiene píxeles blancos pequeños y dispersos, el algoritmo puede clasificarlos falsamente

como una detección válida de glóbulos blancos. Adicionalmente, si hay sobreestimación de los cuadros delimitadores y espacio vacío, a causa de que, los cuadros delimitadores pueden capturar múltiples objetos, especialmente en casos en los que los glóbulos blancos están agrupados [6]. Por otro lado, una solución que se implementa para observar en un problema de segmentación es la intersección sobre unión (IoU), como se ha visto en otras entregas. Asimismo, otra sugerencia es las métricas basadas en formas. En lugar de utilizar cuadros delimitadores, utilice la detección basada en contornos y mida la similitud de las formas detectadas con las formas conocidas de los glóbulos blancos[7]

3. Procesamiento de la base de datos

- ¿Exactamente cuál es el formato de las predicciones? Describa explícitamente qué información contiene el diccionario de predicciones.

Respuesta

Las predicciones se encuentran en formato .json y se organizan en el diccionario de predicciones. El diccionario de predicciones contiene las llaves "image_id", "category_id", "bbox" y "score", y busca retornar información acerca de la predicción de la anotación. La llave "image_id" almacena el identificador único de cada imagen que garantiza ser un valor exclusivo. La llave "category_id" indica la clase detectada en cada imagen, con valores del 1 al 3, que representan plaquetas, glóbulos rojos y glóbulos blancos respectivamente. La llave "bbox" almacena las coordenadas x, y, w, h del componente conexo más grande, lo que corresponde a las dimensiones del bounding box de cada predicción. Finalmente, la llave "score" representa el porcentaje de True dentro de la ventana de detección, es decir, el porcentaje de píxeles que fueron clasificados correctamente como parte del objeto de interés dentro de la ventana de detección (bbox).

4. Preprocesamiento de la base de datos

- Muestre y describa los resultados cualitativos (imágenes e histogramas) de su experimentación con el valor de gamma en la transformación. ¿Cuáles resultados fueron mejores? Justifique.

Respuesta

La elección de los valores de γ más adecuados para visualizar la célula objetivo depende del canal seleccionado para la modificación en escala de grises de la imagen. En el análisis realizado, decidimos experimentar con dos canales para observar y analizar las diferencias en la transformación de la imagen entre ambos. Las imágenes correspondientes a cada canal se muestran en la [figura 2](#).




Figure 2. Exploración de canales de grises para la imagen seleccionada.

En la [figura 3](#) se muestra la transformación de las intensidades de gris mediante correcciones gamma para el canal *blue*. En esta transformación, se observa que un valor de $\gamma < 1$ facilita la visualización de la célula blanca, ya que resalta el color de la tinción presente en ella. Esta transformación tiene asociado un histograma con un rango reducido y centrado en la zona derecha que corresponde a las intensidades claras. El valor de γ seleccionado es más adecuado en este caso debido a que la imagen original del canal *blue* presenta principalmente intensidades claras en el fondo e intensidades oscuras en la célula objetivo. Al aplicar la transformación con $\gamma < 1$, tanto las intensidades claras como las oscuras se modifican gradualmente sin alteraciones abruptas. Como resultado, las intensidades claras se aclaran aún más y esto ocasiona una mejora en la diferenciación entre el fondo y la célula objetivo, facilitando así su detección.

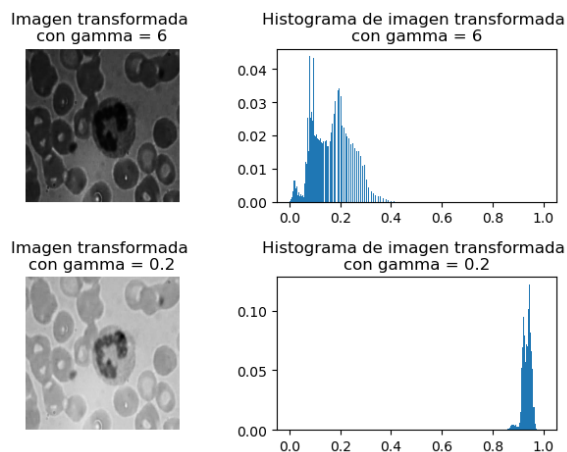


Figure 3. Imagen del canal *blue* transformada por medio de correcciones gamma para $\gamma > 1$ y $\gamma < 1$. En la columna izquierda se evidencia la imagen transformada y en la columna derecha su respectivo histograma.

Por otro lado, en la [figura 4](#) se presenta la transformación de las intensidades de gris mediante correcciones gamma para el canal *red*. En este caso, se obtiene un efecto opuesto al de la transformación anterior. La imagen obtenida al explorar el canal *red* pre-

senta intensidades oscuras en el fondo e intensidades claras en la tinción presente en la célula objetivo. Una vez realizada la transformación de dicha imagen se observa que un valor de $\gamma > 1$ facilita la visualización de la célula objetivo, ya que mejora su distinción frente al resto de los elementos presentes en la imagen. Esta transformación tiene asociado un histograma con un rango intermedio y centrado en la zona izquierda correspondiente a las intensidades oscuras. El valor de γ seleccionado es el más adecuado en este caso, ya que ocasiona que las intensidades oscuras y medias se oscurezcan aún más, mientras que las intensidades más claras se conserven sin mayores modificaciones. Como resultado, se genera un mayor contraste entre el fondo y la célula objetivo, facilitando su detección.

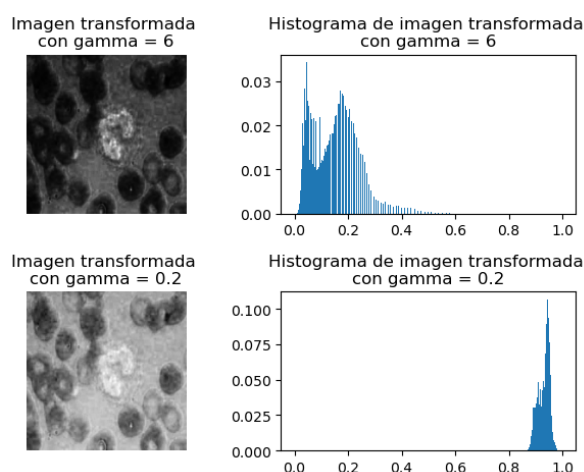


Figure 4. Imagen del canal *red* transformada por medio de correcciones gamma para $\gamma > 1$ y $\gamma < 1$. En la columna izquierda se evidencia la imagen transformada y en la columna derecha su respectivo histograma

- Muestre y describa los resultados luego de usar la ecualización y especificación por separado ¿Los resultados fueron mejores que la imagen original? ¿Por qué?

Respuesta

Para realizar el procesamiento de ecualización y especificación se utilizó la imagen en escala de grises del canal *red*. Los resultados obtenidos se muestran en la [figura 5](#). La imagen modificada mediante ecualización tiene como objetivo generar un histograma uniformemente distribuido con el fin de generar un mayor contraste en la imagen. Esto coincide con la imagen transformada, donde se observa un mayor contraste entre las intensidades claras y oscuras. Además, se puede observar que la frecuencia de aparición de todas las intensidades es similar, lo que indica que los valores de intensidad pueden estar presentando una distribución

más uniforme.

Por otro lado, la especificación tiene como objetivo imponer una forma específica al histograma de la imagen de acuerdo con uno seleccionado previamente. La imagen seleccionada presentaba, en su mayoría, intensidades muy oscuras, por lo que se esperaba que el histograma resultante mostrara una mayor frecuencia de intensidades oscuras y sus intensidades oscuras originales se oscurecieran aún más. Asimismo, las intensidades claras eran pocas, por lo que se esperaba que estas tuvieran menor frecuencia. Como resultado, se esperaba un mayor contraste entre las áreas claras y oscuras de la imagen transformada.

En cuanto a si los resultados obtenidos fueron mejores que los de la imagen original, la respuesta es sí en el caso de especificación. Esto se debe a que el contraste entre las intensidades claras y oscuras de la imagen se ve considerablemente incrementado en comparación con la imagen original, esto ocasiona que la detección del glóbulo blanco sea facilitada por sus bordes bien definidos y su intensidad mucho más clara que el resto de los elementos presentes en la imagen. Respecto a la ecualización, no podemos afirmar con certeza si los resultados son mejores, aunque se observa una diferencia clara en las intensidades que distinguen el glóbulo blanco de los demás elementos, este tiene una intensidad muy similar a la del fondo de la imagen, lo que puede ocasionar confusión a la hora de realizar la detección. Sin embargo, se destaca como aspecto positivo que presenta un mayor contraste en los bordes del glóbulo blanco en comparación con la imagen original, lo que podría ser una ventaja comparativa.




Figure 5. Imagen original y modificada mediante transformaciones del histograma asociado a la misma.

5. Experimentación

- Adjunte y describa la tabla con los resultados del mAP de los experimentos. Analice todos sus experimento, destacando porque cada experimento tuvo esos resultados.

Respuesta

Los experimentos se llevaron a cabo utilizando umbralización por percentil, ya que, según lo observado

en la *sección 1 - Umbralización*, este método produjo resultados significativamente mejores en comparación con la umbralización basada en un valor arbitrario. Se realizaron tres experimentos con las transformaciones : i) transformación de gamma, ii) ecualización y iii) especificación. Para cada uno de estos experimentos, se almacenaron los dos mejores resultados de mAP, variando el valor del percentil en un rango de 3 a 10 con intervalos de 0.5. En el caso particular del experimento de transformación de gamma, se probó un rango de valores de gamma variando de 0.1 a 5 en intervalos de 0.5. Los resultados obtenidos están registrados en la *tabla 6*.

	Preprocesamiento							
	Gamma				Ecualización		Especificación	
	Gamma	Percentile	Gama	Percentile	Percentile	Percentile	Percentile	Percentile
Valores parametros	4	10	4	9	10	9	10	9
mAP	0.5846153243430648	0.5846153242959191	0.5846153243430648	0.5846153242959191	0.5846153243430648	0.5846153242959191	0.5846153243430648	0.5846153242959191

Figure 6. Tabla de mAP obtenidos con diferentes transformaciones y parámetros.

No obstante, estos resultados no concuerdan con lo esperado, ya que todos los mAP obtenidos son iguales para los tres casos. Tras haber realizado un análisis exhaustivo en las funciones realizadas, se pudo identificar que el problema se encontraba en que al momento de realizar la umbralización por percentil, todas las imágenes que eran retornadas eran iguales sin importar que las imágenes ingresadas por parámetro y los umbrales obtenidos utilizando *np.percentile* fuesen diferentes. Se intentó modificar el código para solucionar este error pero tras varios intentos, no fue posible. Las modificaciones realizadas para este análisis de error no se encuentran en el código adjunto debido a que se encontraba desordenada e impedía un entendimiento preciso del código antes realizado.

Sin embargo, consideramos que de haber tenido un código correcto, la imagen transformada mediante especificación pudo haber arrojado un mejor mAP. Esto debido a que esta imagen presenta un mayor contraste entre la célula objetivo y el resto de elementos y el fondo que se encuentran en la imagen. Por lo tanto, esto podría facilitar en gran medida la detección del objetivo para el modelo, mejorando un ello el rendimiento del mismo. Por el contrario, la imagen con peor mAP pudo ser obtenida del experimento realizado con la transformación de ecualización, ya que como se mencionó antes, en estas las intensidades de la célula objetivo son similares al fondo, lo que puede provocar que hayan confusiones al momento de realizar la identificación.

- ¿El pre-procesamiento siempre fue útil en sus ex-

perimentos, es decir, quitar el preprocesamiento no generaría cambios?

Respuesta

Sí, el pre-procesamiento fue muy útil en los experimentos realizados y el quitarlo generaría cambios en el desempeño del modelo, en nuestro caso particular evaluado por el índice de jaccard debido a que los resultados de mAP no corresponden con lo esperado y es muy probable que el obtenido no sea correcto. Al analizar el índice de jaccard obtenido a través de la función *view_redseobtuvieron mejores indices de jaccard para las imágenes procesadas, porejemplo, el mayor valor obtenido fue de 0.597415031*.

6. Prueba

- Incluya y describa los resultados, incluyendo el subplot, la gráfica de la curva P-C, y el mAP.

Respuesta




Figure 7. La gráfica muestra la relación entre la cobertura y la precisión en distintos niveles de Jaccard para test (J=0.4, J=0.3, J=0.2). Las curvas representan el comportamiento de la precisión en función de la cobertura, con líneas discontinuas indicando tendencias generales. Se observa que a medida que la cobertura aumenta, la precisión tiende a disminuir, lo que es una tendencia típica en evaluaciones de rendimiento de modelos. El valor de mAP se mantiene constante en 0.35504 para los tres valores de J analizados.

- ¿Son congruentes sus resultados en la prueba con los obtenidos en la validación?

Respuesta

No, no son congruentes, al comparar esta gráfica con la anterior, se observa que el mAP ha disminuido de 0.5846 a 0.3550, lo que sugiere una caída en el rendimiento del modelo en términos de precisión y cobertura. Esta diferencia puede deberse a cambios en




Figure 8. Resultados de detección de globulos blancos. Cada fila muestra comparaciones entre la predicción del modelo (izquierda) y la anotación real (derecha). Los cuadros rojos indican las regiones detectadas. Se incluyen los valores de IoU (Intersection over Union) para evaluar la precisión de las detecciones

los datos de prueba, modificaciones en la estrategia de predicción o ajustes en el modelo. La forma más irregular de la curva verde en esta nueva gráfica también indica una mayor variabilidad en el comportamiento de la precisión a medida que aumenta la cobertura.

- ¿Qué problemas pueden observar en sus resultados cualitativos?

Respuesta

En primer lugar, Los resultados cualitativos revelan varios problemas potenciales en el rendimiento del modelo. Uno de los principales problemas es la desalineación de los recuadros delimitadores, en los que los recuadros previstos no coinciden perfectamente con los objetos reales, probablemente debido a un umbral inadecuado o al procesamiento de máscaras. Además, hay falsos positivos, lo que significa que el modelo a veces detecta objetos inexistentes, lo que puede deberse a una corrección gamma excesiva que aumenta el ruido. A la inversa, los falsos negativos indican que no se detectan algunos objetos reales, lo que reduce la recuperación, posiblemente debido a un umbral de Jaccard estricto de 0,6. Además, puede producirse una segmentación excesiva o insuficiente en función del enfoque de umbral: si es demasiado agresivo, las regiones detectadas pueden ser demasiado pequeñas, mientras que si es demasiado permisivo, los objetos pueden ser demasiado grandes. Por último, la estabilidad del mAP en función de los valores de Jaccard (0,46 para $J=0,4$, $J=0,3$ y $J=0,2$) sugiere que el modelo no es muy sensible a la precisión de la localización, lo que significa que las detecciones podrían no estar bien afinadas. Adicionalmente, si el umbral de base en el percentil es demasiado alto o demasiado bajo, puede segmentar incorrectamente la imagen, excluyendo regiones relevantes o incluyendo artefactos

no deseados

- ¿Cómo mejorarían su método?

Respuesta

Para mejorar el rendimiento del modelo, una mejora clave sería optimizar las técnicas de preprocesamiento, en particular la corrección gamma y la ecualización del histograma. Actualmente, el valor gamma puede sobre o subrealzar el contraste de la imagen, lo que genera falsos positivos o detecciones fallidas. Un mejor enfoque sería ajustar dinámicamente el valor gamma en función de la distribución de intensidad de la imagen en lugar de utilizar un valor fijo. Además, se podría utilizar la ecualización de histograma adaptativa. Asimismo, Otra área crítica para mejorar es el método de umbralización utilizado para la segmentación. En lugar de utilizar un percentil fijo o un umbral arbitrario, se podrían explorar técnicas de umbralización adaptativa o multiumbral. Métodos como el umbralización de Otsu o la umbralización adaptativa gaussiana permitirían al modelo segmentar objetos de forma más eficaz en distintas condiciones de iluminación. Además, la incorporación de operaciones morfológicas como la dilatación y la erosión podría ayudar a refinar las regiones segmentadas al reducir el ruido y mejorar los límites de los objetos. No obstante, también se podrían mejorar la métrica de evaluación y los criterios de detección del modelo para reducir los falsos positivos y los falsos negativos. El umbral actual de Jaccard (0,6) podría ser demasiado estricto, lo que haría que el modelo descartara detecciones que están ligeramente desalineadas. Se podría probar un umbral más bajo o una ponderación de confianza basada en IoU para equilibrar la recuperación y la precisión. Además, en lugar de seleccionar solo el componente conectado más grande en la segmentación, se podría explorar un método de detección basado en contornos para detectar múltiples objetos en una sola imagen de manera más efectiva

References

- [1] Z. F. Mohammed and A. A. Abdulla, "Thresholding-based White Blood Cells Segmentation from Microscopic Blood Images," UHD Journal of Science and Technology, vol. 4, no. 1, pp. 9–17, Feb. 2020, doi: 10.21928/uhdjst.v4n1y2020.pp9-17.
- [2] F. Prezja, L. Annala, S. Kiiskinen, S. Lahtinen, and T. Ojala, "Adaptive Variance Thresholding: a novel approach to improve existing deep transfer vision models and advance automatic Knee-Joint osteoarthritis classification," arXiv (Cornell University), Jan. 2023, doi: 10.48550/arxiv.2311.05799.

- [3] R. C. Gonzalez, R. E. Woods, and S. L. Eddins, Digital image processing using MATLAB. 2003. [Online]. Available: <http://cds.cern.ch/record/1350801>
- [4] B. Preim and C. Botha, “Image analysis for medical visualization,” in Elsevier eBooks, 2013, pp. 111–175. doi: 10.1016/b978-0-12-415873-3.00004-3.
- [5] G. S. Cover, W. G. Herrera, M. P. Bento, S. Appenzeller, and L. Rittner, “Computational methods for corpus callosum segmentation on MRI: A systematic literature review,” Computer Methods and Programs in Biomedicine, vol. 154, pp. 25–35, Nov. 2017, doi: 10.1016/j.cmpb.2017.10.025.
- [6] W. Xie, J. A. Noble, and A. Zisserman, “Microscopy cell counting and detection with fully convolutional regression networks,” Computer Methods in Biomechanics and Biomedical Engineering Imaging y Visualization, vol. 6, no. 3, pp. 283–292, May 2016, doi: 10.1080/21681163.2016.1149104.
- [7] A. H. Alharbi, C. V. Aravinda, M. Lin, P. S. Venugopala, P. Reddicherla, and M. A. Shah, “Segmentation and classification of white blood cells using the UNET,” Contrast Media y Molecular Imaging, vol. 2022, no. 1, Jan. 2022, doi: 10.1155/2022/5913905.

Realizado en L^AT_EX